

Министерство образования Республики Беларусь
Учреждение образования
«Брестский Государственный технический университет»
Кафедра ИИТ

Лабораторная работа №1

По дисциплине «Интеллектуальный анализ данных»

Тема: «РСА»

Выполнил:

Студент 3 курса

Группы ИИ-25

Бекназарова А. С.

Проверил:

Андренко К. В.

Брест 2026

Цель работы: научиться применять метод PCA для осуществления визуализации данных.

Задание: используя выборку по варианту, осуществить проецирование данных на плоскость первых двух и трех главных компонент (двумя способами: 1. вручную через использование `numpy.linalg.eig` для вычисления собственных значений и собственных векторов и 2. с помощью `sklearn.decomposition.PCA` для непосредственного применения метода PCA – два независимых варианта решения), выполнить визуализацию полученных главных компонент с использованием средств библиотеки `matplotlib`, обозначая экземпляры разных классов с использованием разных цветовых маркеров, используя собственные значения, рассчитанные на этапе 1, вычислить потери, связанные с преобразованием по методу PCA. Сделать выводы, оформить отчет по выполненной работе, загрузить исходный код и отчет в соответствующий репозиторий на github.

Вариант 2

Ход работы

Код программы:

```
# Ручной PCA
def pca_manual(data, n_components=2):
    data_centered = data - data.mean(axis=0)

    cov_matrix = np.cov(data_centered.T)
    eigenvalues, eigenvectors = np.linalg.eig(cov_matrix)

    sorted_idx = np.argsort(eigenvalues)[::-1]
    eigenvalues = eigenvalues[sorted_idx]
    eigenvectors = eigenvectors[:, sorted_idx]
    components = eigenvectors[:, :n_components]

    data_reduced = data_centered.dot(components)
    return data_reduced, eigenvalues, eigenvectors

X_manual_2, eigenvalues, eigenvectors = pca_manual(X_scaled, n_components=2)
X_manual_3 = (X_scaled - X_scaled.mean(axis=0)).dot(eigenvectors[:, :3])
print("\nРучной PCA выполнен.")
print("Первые 5 собственных значений:", np.round(eigenvalues[:5], 4))

# PCA через sklearn
pca_sklearn_2 = PCA(n_components=2)
X_sklearn_2 = pca_sklearn_2.fit_transform(X_scaled)

pca_sklearn_3 = PCA(n_components=3)
X_sklearn_3 = pca_sklearn_3.fit_transform(X_scaled)

print("\nsklearn PCA выполнен.")
print("Объяснённая дисперсия (2 компоненты):",
      np.round(pca_sklearn_2.explained_variance_ratio_, 4))
print("Сумма объяснённой дисперсии (2 компоненты):",
      round(pca_sklearn_2.explained_variance_ratio_.sum(), 4))
```

Результат:

Исходный размер данных: (615, 13)

Первые 5 строк:

	Category	Age	Sex	ALB	ALP	ALT	AST	BIL	CHE	CHOL	CREA	GGT
PROT												
1	0=Blood Donor	32	m	38.5	52.5	7.7	22.1	7.5	6.93	3.23	106.0	12.1
69.0												
2	0=Blood Donor	32	m	38.5	70.3	18.0	24.7	3.9	11.17	4.80	74.0	15.6
76.5												
3	0=Blood Donor	32	m	46.9	74.7	36.2	52.6	6.1	8.84	5.20	86.0	33.2
79.3												
4	0=Blood Donor	32	m	43.2	52.0	30.6	22.6	18.9	7.33	4.74	80.0	33.8
75.7												
5	0=Blood Donor	32	m	39.2	74.1	32.6	24.8	9.6	9.15	4.32	76.0	29.9
68.7												

Типы данных:

Category	str
Age	int64
Sex	str
ALB	float64
ALP	float64
ALT	float64
AST	float64
BIL	float64
CHE	float64
CHOL	float64
CREA	float64
GGT	float64
PROT	float64

dtype: object

Колонки: ['Category', 'Age', 'Sex', 'ALB', 'ALP', 'ALT', 'AST', 'BIL', 'CHE', 'CHOL', 'CREA', 'GGT', 'PROT']

Пропуски до обработки:

Age	0
Sex	0
ALB	1
ALP	18
ALT	1
AST	0
BIL	0
CHE	0
CHOL	10
CREA	0
GGT	0
PROT	1

dtype: int64

Пропуски после обработки:

0 пропусков осталось

Размер данных после предобработки: (615, 12)

Ручной PCA выполнен.

Первые 5 собственных значений: [2.4657 1.9023 1.4203 1.1464 0.9815]

sklearn PCA выполнен.

Объяснённая дисперсия (2 компоненты): [0.2051 0.1583]

Сумма объяснённой дисперсии (2 компоненты): 0.3634

Потери информативности

Полная информация (сумма всех собств. значений): 12.0195

Информация в 2 компонентах: 4.3681

Информация в 3 компонентах: 5.7884

Потери при 2 компонентах: 63.66%

Потери при 3 компонентах: 51.84%

Проверка через sklearn:

Потери при 2 компонентах: 63.66%





Потери при 3 компонентах: 51.84%

Доля объяснённой дисперсии по компонентам:

PC1: 20.51%

PC2: 15.83%

PC3: 11.82%



Вывод: научились применять метод PCA для осуществления визуализации данных.