

Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №1

По дисциплине: «Интеллектуальный анализ данных»
Тема: «РСА»

Выполнил:
Студент 4 курса
Группы ИИ-25
Трошин И.Д.
Проверила:
Андренко К.В.

Цель работы: научиться применять метод PCA для осуществления визуализации данных.

Общее задание

1. Используя выборку по варианту, осуществить проецирование данных на плоскость первых двух и трех главных компонент (двумя способами: 1. вручную через использование `numpy.linalg.eig` для вычисления собственных значений и собственных векторов и 2. с помощью `sklearn.decomposition.PCA` для непосредственного применения метода PCA – два независимых варианта решения);
2. Выполнить визуализацию полученных главных компонент с использованием средств библиотеки `matplotlib`, обозначая экземпляры разных классов с использованием разных цветовых маркеров;
3. Используя собственные значения, рассчитанные на этапе 1, вычислить потери, связанные с преобразованием по методу PCA. Сделать выводы;
4. Оформить отчет по выполненной работе, загрузить исходный код и отчет в соответствующий репозиторий на github..

Вариант 13

№ варианта	Выборка	Класс
13	exasens.zip	Diagnosis ID

Ход работы


Exasens — набор данных выдыхаемого конденсата у пациентов с респираторными заболеваниями. Исходный файл имеет структуру:

Diagnosis	ID	Imaginary Part		Real Part		Gender	Age	Smoking
		Min	Avg.	Min	Avg.			
COPD	301-4	-320.61	-300.5635307	-495.26	-464.1719907	1	77	2
COPD	302-3	-325.39	-314.7503595	-473.73	-469.2631404	0	72	2
COPD	303-3	-323	-317.4360556	-476.12	-471.8976667	1	73	3
COPD	304-4	-327.78	-317.3996698	-473.73	-468.856388	1	76	2


Gender	Smoking
Male=1	Non-smoker=1
Female=0	Ex-smoker=2
	Active-smoker=3

Результат Ручной PCA:

2 главные компоненты



3 главные компоненты



Признаки: ['Imaginary_Min', 'Imaginary_Avg', 'Real_Min', 'Real_Avg', 'Gender', 'Age', 'Smoking']


Собственные значения:

$\lambda_1 = 2.7708$ (доля дисперсии = 39.48%)
 $\lambda_2 = 1.3129$ (доля дисперсии = 18.71%)
 $\lambda_3 = 1.1369$ (доля дисперсии = 16.20%)
 $\lambda_4 = 0.9029$ (доля дисперсии = 12.87%)
 $\lambda_5 = 0.7542$ (доля дисперсии = 10.75%)
 $\lambda_6 = 0.1304$ (доля дисперсии = 1.86%)
 $\lambda_7 = 0.0094$ (доля дисперсии = 0.13%)


[k=2] объяснённая дисперсия = 58.19%		потеря = 41.81%		MSE реконструкции = 0.4181
[k=3] объяснённая дисперсия = 74.39%		потеря = 25.61%		MSE реконструкции = 0.2561

Sklearn PCA:

2 главные компоненты



3 главные компоненты



Признаки: ['Imaginary_Min', 'Imaginary_Avg', 'Real_Min', 'Real_Avg', 'Gender', 'Age', 'Smoking']

Собственные значения (explained_variance_, все компоненты):

$\lambda_1 = 2.7708$ (доля дисперсии = 39.48%)
 $\lambda_2 = 1.3129$ (доля дисперсии = 18.71%)
 $\lambda_3 = 1.1369$ (доля дисперсии = 16.20%)

$\lambda_4 = 0.9029$ (доля дисперсии = 12.87%)
 $\lambda_5 = 0.7542$ (доля дисперсии = 10.75%)
 $\lambda_6 = 0.1304$ (доля дисперсии = 1.86%)
 $\lambda_7 = 0.0094$ (доля дисперсии = 0.13%)

[k=2] объяснённая дисперсия = 58.19% | потеря = 41.81% | MSE реконструкции = 0.4181
 [k=3] объяснённая дисперсия = 74.39% | потеря = 25.61% | MSE реконструкции = 0.2561

1. Сколько признаков вошло в анализ и какие колонки потребовалось удалить перед PCA?

2. Каков уровень потерь информации при проецировании Exasens на 2 и 3 компоненты?

1) В анализ вошло 7 признаков:

'Imaginary_Min', 'Imaginary_Avg', 'Real_Min', 'Real_Avg', 'Gender', 'Age', 'Smoking'

Удалены перед PCA две колонки:

- ID — служебный идентификатор пациента (не измеренная величина, произвольный ключ записи, диагностической информации не несёт).
- Diagnosis — целевой класс; по условию задания используется только для визуализации (раскраски точек на графике), а не как признак для самого PCA.

2) Потери информации при проецировании

k (компонент)	Объяснённая дисперсия	Потеря	MSE реконструкции
2	58.19%	41.81%	0.4181
3	74.39%	25.61%	0.2561

Оба способа дали одинаковые значения. Потеря достаточно высокая — дисперсия у Exasens распределена почти равномерно между первыми пятью компонентами (λ от 2.77 до 0.75), поэтому сжатие в 2–3 измерения теряет заметную часть информации; только 6-я и 7-я компоненты ($\lambda = 0.13$ и 0.009) вносят пренебрежимо малый вклад.

Вывод: научился применять метод PCA для осуществления визуализации данных